

CHALLENGE FIAP × LOCAWEB · SPRINT 3

FlowGuard

Motor Preditivo de Quebra de OLA com Deep Learning

Artificial Intelligence e Deep Learning Application — Modelagem

Grupo FiveSight · Turma 2TSCPV · Projeto FlowGuard

RM	INTEGRANTE
566274	Arthur Nishiyama
561541	Diogo Santana
562481	Isabella Mattar
562733	Karen Akemi



0,20%
dos incidentes
quebram o OLA

Preparação dos Dados e Engenharia de Features

Base: LW-DATASET.xlsx — 122.543 incidentes da Locaweb (jan/2023 a dez/2025).

- **Tratamento de nulos:** colunas categóricas ausentes (Produto, Categoria, Subcategoria) preenchidas como “Desconhecido”; datas de abertura inválidas descartadas.
- **Codificações:** variáveis categóricas (Prioridade, Categoria, Produto, Grupo designado, Aberto por, Cluster de chegada) via One-Hot Encoding.
- **Normalização:** variáveis numéricas (hora de abertura, dia da semana) padronizadas com StandardScaler (média 0, desvio 1).
- **Features de calendário criadas:** hora_abertura e dia_semana_abertura, extraídas do timestamp de abertura do chamado.
- **Feature de clusterização:** cluster_chegada (K-Means, k=3) agrupa incidentes por perfil de horário/dia de chegada.
- **Correção de vazamento:** a duração do atendimento foi removida das features — só existe depois que o incidente é resolvido (detalhe no próximo slide).

220

colunas no vetor de entrada
após One-Hot Encoding

0,20%

taxa de quebra de OLA
(classe extremamente rara)

3

perfis de chegada identificados
pela clusterização K-Means

Vazamento de Dados: Identificado e Corrigido



Versão com vazamento

- tempo_resolucao_horas e um cluster derivado dela entravam como features do modelo.
- Essa duração só existe DEPOIS que o incidente é resolvido — mas o modelo precisa decidir o risco na ABERTURA do chamado.
- O próprio target é definido comparando a duração a um limite de SLA: usar a duração como feature é dar a resposta ao modelo.



Versão corrigida

- Duração removida das features — mantida só como referência de EDA, nunca como entrada do modelo.
- Features usam somente informação disponível na abertura: Prioridade, Categoria, Produto, Equipe, Canal, hora e dia da semana.
- Clusterização recalculada a partir do horário de abertura (“perfil de chegada”), não da duração.

Mesmo tipo de problema identificado e banido pela seção de auditoria de Data Leakage do notebook de Machine Learning do grupo — lá, para a variável “Duração”, pelo mesmo motivo.

2. DEFINIÇÃO DE BASELINE

Baseline: Sempre Prever “Não Vai Quebrar”

Como a quebra de OLA é rara (0,20% dos incidentes), o baseline mais simples e mais informativo é prever sempre a classe majoritária — “nunca vai quebrar”. Ele custa zero para implementar e expõe diretamente o problema da Acurácia como métrica: um baseline que erra 100% dos casos que realmente importam ainda parece excelente olhando só para a acurácia geral.

Nenhuma melhoria de modelo vale a pena se não superar isso.

99,8%

acurácia geral

0,00

Recall na classe de quebra de OLA

Regressão Logística como Etapa de Comparação

Antes de justificar a Rede Neural, treinamos uma Regressão Logística com `class_weight` balanceado sobre exatamente as mesmas features (sem vazamento) e o mesmo split treino/teste. É um modelo linear, rápido de treinar e fácil de auditar — se ele já captura boa parte do sinal, isso já é informação valiosa.

Limitações discutidas

- Modelo linear no espaço das features: não captura interações entre variáveis categóricas.
- Ex.: “prioridade alta + equipe X + horário Y” pode ter efeito conjunto diferente da soma dos efeitos individuais — é esse padrão não-linear que a ANN tenta capturar melhor.

0,82

Recall (classe 1)

0,016

Precisão (classe 1)

0,952

ROC-AUC

Comparativo: Baseline vs. Clássico vs. ANN

Modelo	Recall	Precisão	F1	ROC-AUC
Baseline (classe majoritária)	0,00	0,00	0,00	—
Regressão Logística (clássico)	0,82	0,016	0,031	0,952
ANN — Modelo Complexo	0,88	0,020	0,030	0,942

Métricas calculadas sobre a classe de interesse (quebra de OLA).

Recall é a métrica prioritária de negócio

O custo de um Falso Negativo (dizer que o OLA não vai quebrar, quando na verdade quebra) é muito maior que o custo de um Falso Positivo. A ANN supera o baseline por larga margem e supera ligeiramente o modelo clássico — um ganho honesto, não inflado por vazamento de dados.

Reprodutibilidade do Processo

1

Dataset e versionamento

LW-DATASET.xlsx (122.543 incidentes, 02/01/2023 a 31/12/2025) — mesmo arquivo-fonte usado pelas disciplinas de Machine Learning e Data Visualization.

2

Seed fixa em todo o pipeline

random_state = 42 no split, na clusterização K-Means, na Regressão Logística e nas 3 configurações de ANN — a comparação entre modelos não depende de sorte de inicialização.

3

Divisão treino/teste/validação

train_test_split 80/20 com stratify=y (obrigatório dado que a classe positiva é 0,20% da base); cada ANN reserva ainda 20% do treino para validação interna (validation_split=0,2).

4

Tabela de experimentos

5 configurações testadas sobre o mesmo split e as mesmas features: Baseline, Regressão Logística, Modelo_Base, Modelo_Complexo e Modelo_Alto_Dropout (ANN).


5

Controle de overfitting


EarlyStopping monitorando val_loss com restore_best_weights=True em todas as ANN — substitui a cross-validation formal nesta etapa de MVP, dado o custo computacional e o tamanho da base.

Evidência Visual da Execução Real

Capturas de tela retiradas diretamente da execução do notebook EC_Sprint_3_FLOWGUARD_FIVESIGHT_DeepL.ipynb.



Curvas de perda (treino x validação) das 3 arquiteturas de ANN testadas.



Matriz de confusão — ANN (Modelo Complexo) no conjunto de teste.

O que os Resultados Indicam e Próximos Passos

O que os resultados indicam

- A ANN supera o baseline por larga margem, mas o ganho sobre o modelo clássico é modesto — o sinal disponível nas features de abertura é majoritariamente linear.
- Sem sinais fortes de overfitting: o EarlyStopping interrompeu o treino cedo (5 a 15 épocas) e restaurou os melhores pesos de validação em todas as configurações.
- Precisão baixa em todos os modelos (Recall alto, Precisão $\sim 0,02$) é esperado dado o desbalanceamento extremo (1 quebra para cada ~ 494 incidentes elegíveis) — não é falha de implementação.

Melhorias objetivas — Sprint 4

- **Novas features:** carga atual da equipe e histórico recente do item de configuração.
- **Modelos de árvore:** testar Random Forest / Gradient Boosting para capturar interações não-lineares.
- **Tuning mais extenso:** grid/random search nos hiperparâmetros da ANN.
- **Balanceamento:** avaliar SMOTE ou undersampling controlado da classe majoritária.
- **Threshold tuning:** ajustar o limiar de decisão além do padrão 0,5, otimizando para Recall-alvo.

Status da Modelagem

MVP técnico validado localmente: pipeline sem vazamento de dados, baseline e modelo clássico comparados a uma Rede Neural, com reprodutibilidade documentada (seeds, split estratificado, tabela de experimentos).

Plano de Evolução — Sprint 4

- **Modelo final:** features enriquecidas + modelo de árvore ou ANN ajustada, escolhido pelo comparativo de Recall/ROC-AUC.
- **Explicabilidade:** importância de variáveis (permutation importance / SHAP) para justificar cada alerta gerado.
- **Entrega executiva:** modelo integrado ao FlowGuard em produção (Cloud Solutions) e refletido no dashboard (Data Visualization).